LLM 컨텍스트 설계 전략 — 플랫폼 비교표

> 기준: "LLM은 기억하지 않는다 — 컨텍스트 설계가 서비스다" 관점의 10가지 핵심 전략
> Aimbase는 Gap 5개(대화 요약, Smart Routing, 응답 캐시, 메모리 분리, Fallback) 보강 후 기준

종합 비교

#	전략	Aimbase	Open WebUI	Dify	n8n
1	**컨텍스트 윈도우 관리**	**A**	C+	A	C
2	**모델 라우팅 (비용 최적화)**	**A-**	D	A-	C+
3	**캐싱 (응답/프롬프트/임베딩)**	**B+**	D	A-	D
4	**RAG 품질**	**A+**	A-	A-	C
5	**대화 메모리 구조 분리**	**B+**	C	C+	D
6	**프롬프트 관리**	**A**	C+	A+	C
7	**출력 길이 제어**	**A-**	A-	A	A-
8	**비동기/배치 처리**	**A**	C	A-	A
9	**재시도/Fallback 전략**	**B+**	D	B+	A-
10	**비LLM 전처리 (규칙/정책)**	**A+**	C	C+	C
	종합	**A-**	**C+**	**B+**	**C+**

상세 비교

1. 컨텍스트 윈도우 관리

> "과거 데이터를 전부 싣지 않고, 필요한 것만 효율적으로 관리"

항목	Aimbase	Open WebUI	Dify	n8n
토큰 기반 자동 트리밍	O (10만 토큰)	X (수동 설정)	O (2000 토큰/500 msg)	X
SYSTEM 메시지 보호	O	X	O	X
대화 요약 압축	**O (Haiku로 자동 요약)**	X	워크플로우로 수동 구성	X
모델별 윈도우 자동 조절	O	X	O	X

2. 모델 라우팅 (비용 최적화)

> "모든 요청에 비싼 모델을 쓰지 않는다"

항목	Aimbase	Open WebUI	Dify	n8n
의도 기반 자동 라우팅	**O (intent classifier)**	X	워크플로우 분기로 가능	워크플로우로 가능
비용 예산 기반 라우팅	**O (routing_config)**	X	X	X
모델별 비용 추적	O (어댑터 내장)	X	O	X
단계별 모델 분리	**O (전처리=저가, 본작업=고가)**	X	워크플로우로 가능	워크플로우로 가능

3. 캐싱

> "같은 질문에 매번 LLM을 호출하지 않는다"

항목	Aimbase	Open WebUI	Dify	n8n
세션/메시지 캐시	O (Redis+DB)	O (로컬DB)	O	X
LLM 응답 캐시	**O (해시 기반)**	X	**O (Annotation Reply)**	X
의미적 캐시 (유사 질문 히트)	**O (임베딩 유사도)**	X	**O**	X

항목	Aimbase	Open WebUI	Dify	n8n
임베딩 결과 캐시	O	O	O	X
프롬프트 prefix 캐시 활용	O (Anthropic native)	X	X	X

4. RAG 품질

> "문맥을 많이 넣는 것보다 정확히 넣는 것"

항목	Aimbase	Open WebUI	Dify	n8n
시맨틱 청킹	**O**	O	O	X (외부 필요)
하이브리드 검색 (BM25+벡터)	**O**	O	O	X
리랭킹 (Cross-encoder)	**O**	O	O	X
Self-RAG (품질 자동 평가)	**O**	X	X	X
HyDE (가설적 문서 생성)	**O**	X	X	X
Multi-Query 변환	**O**	X	O (multi-path)	X
메타데이터 필터링	O	O	O (v1.1)	X

5. 대화 메모리 구조 분리

> "전체 히스토리 대신 구조화된 상태 관리"

항목	Aimbase	Open WebUI	Dify	n8n
단기 기억 (현재 대화)	O	O	O	워크플로우 변수
장기 기억 (세션 간 유지)	**O (메모리 계층)**	O (Memory 기능)	Conversation Variable	X
대화 요약 자동 생성	**O**	X	수동 구성	X
사용자 프로필 컨텍스트	**O**	X	X	X

항목	Aimbase	Open WebUI	Dify	n8n
항상 주입 규칙 vs 검색 지식 분리	**O**	X	부분적	X

6. 프롬프트 관리

> "프롬프트가 모호하면 재시도가 늘어난다"

항목	Aimbase	Open WebUI	Dify	n8n
프롬프트 템플릿 시스템	O	모델별 System Prompt	**O (Prompt IDE, Jinja-2)**	노드 내 편집
버전 관리	O	X	O	X
변수 바인딩	O ({{key}})	X	**O (Jinja-2)**	O (표현식)
토큰 추정	O	X	O	X
A/B 테스트	X	X	**O (Langfuse 연동)**	X

7. 출력 길이 제어

> "출력 토큰도 비용이다"

항목	Aimbase	Open WebUI	Dify	n8n
max_tokens 설정	O (기본 4096)	O	O	O
용도별 프리셋	**O**	X	O (Creative/Balanced/Precise)	X
구조화된 출력 (JSON schema)	O (CR-007)	X	O	O (LangChain)

8. 비동기/배치 처리

> "꼭 실시간일 필요 없는 건 배치로"

항목	Aimbase	Open WebUI	Dify	n8n
스트리밍 응답	O (SSE)	O	O	O
비동기 실행	O (Virtual Thread)	X	O (큐 기반)	**O (Queue mode)**
배치 임베딩	O (20건씩)	X	O	X
워크플로우 병렬 실행	O (DAG 기반)	X	O	**O**
예약/스케줄 실행	계획	X	X	**O (Cron 트리거)**

9. 재시도/Fallback 전략

> "실패 시 전체 재호출이 아니라 똑똑한 재시도"

항목	Aimbase	Open WebUI	Dify	n8n
기본 재시도	O (2회)	X	O	**O (노드별)**
모델 Fallback chain	**O (Opus→Sonnet→Haiku)**	X	O (에러 핸들링 노드)	O (에러 분기)
구조화 출력 파싱 재시도	O (2회)	X	O	X
부분 실패만 재시도	**O**	X	X	O
서킷 브레이커	O (ClaudeCodeTool)	X	X	X

10. 비LLM 전처리

> "LLM은 판단과 생성에만, 기계적 처리는 코드로"

항목	Aimbase	Open WebUI	Dify	n8n
정책 엔진 (SpEL 조건 평가)	**O**	X	워크플로우 조건 분기	워크플로우 분기
PII 마스킹	**O (6종 패턴)**	X	X	X

항목	Aimbase	Open WebUI	Dify	n8n
Rate Limiting	**O (슬라이딩 윈도우)**	O (RBAC)	O	X
쿼터 관리 (토큰/리소스)	**O**	X	X	X
감사 로깅	**O (전 이벤트)**	부분적	O	O
입력 검증/필터링	**O (정책 기반)**	X	코드 노드	Function 노드

포지셔닝 요약

```
                    컨텍스트 설계 성숙도
                    Low ──────────────── High
                     │                    │
자동화/연동 중심    │ n8n (C+)          │
                     │                    │
채팅 UI 중심       │  Open WebUI (C+)   │
                     │                    │
앱 빌더 중심       │         Dify (B+)  │
                     │                    │
오케스트레이션      │       Aimbase (A-) ←── 여기
플랫폼 중심        │                    │
```

각 플랫폼의 본질

플랫폼	본질	잘하는 것	약한 것
Aimbase	LLM 오케스트레이션 백엔드	RAG, 정책, 멀티테넌시, 컨텍스트 설계	UI 에코시스템, 커뮤니티
Open WebUI	셀프호스트 Chat UI	설치 편의성, 채팅 UX, 벡터DB 다양성	메모리, 라우팅, 자동화
Dify	노코드 LLM 앱 빌더	워크플로우 UI, 프롬프트 IDE, 응답 캐시	멀티테넌시, 정책, RAG 깊이

플랫폼	본질	잘하는 것	약한 것
n8n	범용 워크플로우 자동화	앱 연동(500+), 스케줄, 병렬 실행	LLM 전용 기능 전반

Aimbase 고유 차별점 (다른 곳에 없는 것)

1. **Database-per-Tenant 멀티테넌시** — 완전한 데이터 격리
2. **Self-RAG + HyDE** — 검색 품질 자동 평가 + 가설적 문서 생성
3. **SpEL 기반 정책 엔진** — 조건식으로 유연한 규칙 평가
4. **PII 마스킹 6종** — 이메일, 전화, 카드, 주민번호 등
5. **토큰 쿼터 관리** — 테넌트별 사용량 제한

> 작성일: 2026-03-29
> 비교 대상: Open WebUI (최신), Dify (v1.1+), n8n (AI Agent 노드)